📋 Étapes d'une EDA en Séries Temporelles

Étape 1 — Compréhension du dataset

Ce qu'on vérifie :

- Combien de lignes et colonnes
- Quels types de variables (numériques, catégorielles, dates)
- Que représente chaque colonne
- Quelle est la granularité (journalier, horaire, mensuel)
- Y a-t-il plusieurs entités (villes, capteurs, produits)

Étape 2 — Dimension temporelle

Ce qu'on vérifie :

- La colonne date est bien au format datetime
- Les données sont triées chronologiquement
- La période couverte (début → fin)

- La fréquence est régulière (pas de trous)

- Y a-t-il des jours/mois manquants dans la timeline

Étape 3 — Nettoyage

Ce qu'on vérifie :

- Y a-t-il des doublons

- Combien de valeurs manquantes, où, dans quelles colonnes

- Pourquoi elles manquent (aléatoire ou systématique)

- Quel traitement appliquer (interpolation temporelle, forward fill, suppression)

- Y a-t-il des valeurs aberrantes évidentes (négatif pour une température en Kelvin, etc.)

Étape 4 — Statistiques descriptives

Ce qu'on vérifie :

- Moyenne, médiane, écart-type de chaque variable

- Min et max (sont-ils cohérents ?)

- Distribution (symétrique, asymétrique)

- Coefficient de variation (variable stable ou instable)

- Skewness et kurtosis

Étape 5 — Visualisation temporelle

Ce qu'on vérifie :

- Comment chaque variable évolue dans le temps
- Y a-t-il une tendance (hausse, baisse, stable)
- Y a-t-il des pics ou chutes brutales
- Y a-t-il des patterns qui se répètent (saisonnalité visuelle)
- Comportement différent selon les entités (villes)

Étape 6 — Stationnarité

Ce qu'on vérifie :

- La moyenne est-elle constante dans le temps
- La variance est-elle constante dans le temps
- Test statistique ADF : p-value < 0.05 → stationnaire
- Si non stationnaire → faut-il différencier la série

Pourquoi c'est important :

- Certains modèles (ARIMA) exigent la stationnarité

Étape 7 — Saisonnalité

Ce qu'on vérifie :

- Y a-t-il un cycle annuel (12 mois)
- Y a-t-il un cycle hebdomadaire (7 jours)
- Décomposition : séparer tendance + saisonnalité + résidu
- Quelle est la force de la saisonnalité (forte ou faible)

Étape 8 — Outliers

Ce qu'on vérifie :

- Quelles valeurs sont extrêmes (IQR ou Z-score)
- Sont-elles des erreurs ou des événements réels
- Où se situent-elles dans le temps
- Décision : garder, corriger ou supprimer

Étape 9 — Corrélations entre variables

Ce qu'on vérifie :

- Quelles variables sont liées entre elles
- Y a-t-il des corrélations fortes (> 0.7)
- Y a-t-il de la multicolinéarité (problème pour certains modèles)
- Quelles variables sont les plus liées à la cible

Étape 10 — Autocorrélation

Ce qu'on vérifie :

- La valeur d'aujourd'hui dépend-elle d'hier (lag-1)
- Dépend-elle de la semaine dernière (lag-7)
- ACF : montre les corrélations avec tous les lags
- PACF : montre les corrélations directes (sans intermédiaires)
- Quels lags sont significatifs → guide le choix des features

---

Étape 11 — Feature engineering temporel

Ce qu'on crée :

- Variables calendaires : année, mois, jour, saison, jour de la semaine
- Variables cycliques : sin/cos du mois et du jour

- Lags : valeur à t-1, t-7, t-30
- Rolling : moyenne et écart-type glissants sur 7, 14, 30 jours
- Cumuls : somme glissante (ex : pluie cumulée sur 7 jours)

Étape 12 — Variables métier

Ce qu'on crée :
- Des indicateurs qui ont un sens dans le domaine
- Exemple : VRI (indice de risque végétal) à partir de température + pluie
- Avantage : apporte de la connaissance experte au modèle

Étape 13 — Création de la cible

Ce qu'on vérifie :
- La cible est bien décalée vers le futur (shift)
- On prédit bien t+1 ou t+7, pas t actuel
- Pas de fuite d'information (la cible ne contient pas le futur dans les features)

Étape 14 — Split temporel

Ce qu'on vérifie :

- Le split respecte l'ordre chronologique
- Pas de mélange aléatoire (shuffle interdit)
- Train = passé, Test = futur
- Les proportions sont raisonnables (70/15/15 ou 80/20)

Étape 15 — Vérification finale

Ce qu'on vérifie :

- Aucun NaN restant
- Aucune fuite de données
- Les features sont cohérentes
- Le dataset est prêt pour la modélisation

🎯 Résumé en une phrase par étape

#	Étape	Question clé

| 1 | Compréhension | C'est quoi ces données ? |

| 2 | Temporel | Les dates sont propres ? |

| 3 | Nettoyage | Il manque quoi ? |

| 4 | Statistiques | Les chiffres sont logiques ? |

| 5 | Visualisation | Ça ressemble à quoi ? |

| 6 | Stationnarité | La série est stable ? |

| 7 | Saisonnalité | Il y a des cycles ? |

| 8 | Outliers | Il y a des valeurs bizarres ? |

| 9 | Corrélations | Quoi influence quoi ? |

| 10 | Autocorrélation | Hier influence aujourd'hui ? |

| 11 | Features | Quoi ajouter d'utile ? |

| 12 | Métier | Quelle intelligence apporter ? |

| 13 | Cible | On prédit quoi exactement ? |

| 14 | Split | On coupe où dans le temps ? |

| 15 | Vérification | Tout est propre ? |